

## Кратко в предыдущих сериях

Что советуем перед семинаром освежить в памяти из курса статистики:

- Описательные статистики: среднее, частота абсолютная и относительная, выборочные медиана и квантили, их поиск с помощью пакета `numpy`
- Генеральная совокупность, выборка. Алгоритмы сэмплирования с возвращением и без
- Случайные величины, независимость случайных величин, их распределение
- Метод Монте-Карло
- Матожидание и дисперсия
- ЦПТ
- Точечные и интервальные оценки
- Оценки параметров среднего и пропорции

## Тема 1. Бутстреп.

### 0. Цель и задачи

**Цель** — по выборке оценить ее характеристики без применения предположений о генеральной совокупности.

**Задачи:**

- вспомнить статистику (пункты выше)
- узнать, как зависит стандартное отклонение среднего от размера выборки
- понять, что не всегда можно воспользоваться теоретическими оценками
- познакомиться с методом бутстреп, понять принцип его работы
- отметить плюсы и минусы метода
- научиться строить бутстрепные дов. интервалы и сравнить их с дов. интервалами по ЦПТ
- разобрать на примере работу бутстрепа
- узнать, как делать бутстреп, если данные зависят от какой-то характеристики (например, покупки от пользователя)


### 1. Предисловие

#### 1.1 Парадокс бразильских школ

В 1990-х годах в Бразилии стало популярным выступать за сокращение размеров школ.


Многочисленные благотворительные организации и правительственные учреждения финансировали разделение крупных школ, поскольку небольшие школы чаще представлены в группах с высокими средними результатами теста ENEM (бразильский аналог ЕГЭ).

Если отобрать топ-1% школ по среднему баллу, то мы увидим, что школы, попавшие в этот топ-1%, имеют меньшее число учеников:



Почему так?

Посмотрим на зависимость среднего балла от размера школы



Видим, что маленькие школы чаще имеют как высокий, так и низкий средний балл. Но как так?

## 1.2 Стандартное отклонение

Вы уже знакомы со стандартным отклонением. Напомним, что стандартное отклонение случайной величины  $X$  — это  $\sigma_X = \sqrt{\text{Var}(X)}$ , а  $\text{Var}(X)$  — дисперсия случайной величины  $X$ .

На курсе по статистике вы уже видели, что при семплировании Монте-Карло выборки размера  $n$  и подсчете среднего получается отклонение порядка  $\frac{\text{const}}{\sqrt{n}}$ . Сейчас мы получим похожую зависимость.

Пусть нашими наблюдениями  $X_1, \dots, X_n$  будут результаты по ENEM каждому из учеников какой-то их школ. Будем считать эти наблюдения независимыми одинаково распределенными случайными величинами. И пусть стандартное отклонение каждого из  $X_i$  будет  $\sigma$ . Попробуем оценить стандартное отклонение среднего балла по всей школе:

$$\sigma_{\bar{X}} = \sqrt{\text{Var}(\bar{X})} = \sqrt{\frac{1}{n} \text{Var}\left(\sum_{i=1}^n X_i\right)} = \sqrt{\frac{1}{n} \text{Var}(nX_1)} = \frac{\sigma}{\sqrt{n}}.$$



4. Получаем **распределение статистики**, из которого можно:

- оценить стандартную ошибку
- построить доверительный интервал
- сравнивать статистики между группами
- и много чего еще

## 2.5. Но почему выборка бутстрепа того же размера?

Мы хотим получать модели, которые будут наиболее похожи на ту, что у нас есть (т.е. выборку). Поэтому мы берем те же элементы и тот же размер выборки.

**Более строго:** как мы рассмотрели выше, некоторые характеристики, например, стандартное отклонение среднего, зависят от размера выборки. То есть, если мы сгенерируем бутстрепные выборки размера 5 вместо 20, то получим стандартное отклонение среднего примерно в 2 раза больше, чем у исходной выборки.

## 2.6. Почему бутстреп хорош?

- Если выборка репрезентативна настоящему распределению, то бутстреп даёт **правильные оценки** (если размер выборки и кол-во бутстрепных выборок большое, то отклонение от истинного значения статистики будет стремиться к нулю)
- Бутстреп **не зависит от формы распределения** данных
- Бутстреп особенно полезен для **сложных статистик**, для которых **нет готовых формул ошибок** (например, медианы, квантилей)

## 2.7. Ограничения бутстрепа

- **Самое главное — ресурсы:** применение бутстрепа является вычислительно трудоёмкой процедурой. Это становится ощутимо, когда приходится работать с большими объёмами данных и многократно применять бутстреп. Вычисления могут занимать часы, дни и даже недели
- Необходимо учитывать особенности данных. Если мы имеем дело с независимыми одинаково распределёнными случайными величинами, то проблем никаких нет. Но как только у вас возникают связи в данных, то это нужно учитывать. Как? — рассмотрим дальше

## 2.8. Вывод

Бутстреп — это способ статистического вывода, когда:

- Ты **не знаешь или не хочешь предполагать распределение**,
- У тебя есть **достаточно данных** (в идеале — хотя бы десятки наблюдений),
- Тебе нужно оценить **устойчивость, разброс или доверие** к статистике.

Он работает потому, что мы используем саму выборку как **приближение к реальному источнику данных** — и получаем выводы, опираясь на неё, а не на теоретические предположения

## 3. Практика на бутстреп

Ввод [23]:

```
1 import numpy as np
2 import scipy.stats as sps
3 import pandas as pd
4 import matplotlib.pyplot as plt
5 from tqdm.notebook import tqdm
6 from sklift.datasets.datasets import fetch_lenta
7
8 import seaborn as sns
9 sns.set(font_scale=1, palette='Set2')
10 sns.set_style('whitegrid')
```

### 3.1. Описание датасета

Возьмем данные покупок пользователей Amazon в США за период с 2018 по 2022 год.

1. **Survey ResponseID**

Уникальный идентификатор участника опроса. Позволяет связать транзакционные данные с демографической информацией из файла `survey.csv`.

2. **Order date**

Дата оформления заказа на Amazon. Формат: `YYYY-MM-DD`.

3. **Shipping address state**

Состояние (штат) США, указанный в адресе доставки. Может использоваться для географического анализа покупательского поведения.

4. **Purchase price per unit**

Цена за единицу товара в долларах США. Позволяет рассчитывать средний чек и анализировать ценовые категории товаров.

5. **Quantity**

Количество единиц товара, приобретённых в рамках одного заказа.

6. **ASIN/ISBN (Product Code)**

Уникальный идентификатор товара:

- **ASIN** (Amazon Standard Identification Number) для большинства продуктов.
- **ISBN** (International Standard Book Number) для книг.

7. **Title**

Название товара. Может использоваться для категоризации и анализа популярных продуктов.

8. **Category**

Категория товара, определённая Amazon (например, "Electronics", "Books", "Home & Kitchen"). Может быть полезна для сегментации и анализа предпочтений по категориям.

### 3.2. Первичное изучение и преобразование датасета

Прочитаем датасет

Ввод [47]:

```
1 data = pd.read_csv('dataverse_files/amazon-purchases.csv')
2 data
```

Out[47]:

|         | Order<br>Date | Purchase<br>Price Per<br>Unit | Quantity | Shipping<br>Address<br>State | Title                                                            | ASIN/ISBN<br>(Product<br>Code) | Category             | Resp        |
|---------|---------------|-------------------------------|----------|------------------------------|------------------------------------------------------------------|--------------------------------|----------------------|-------------|
| 0       | 2018-12-04    | 7.98                          | 1.0      | NJ                           | SanDisk<br>Ultra 16GB<br>Class 10<br>SDHC UHS-<br>I Memory ...   | B0143RTB1E                     | FLASH_MEMORY         | R_01vNlaye  |
| 1       | 2018-12-22    | 13.99                         | 1.0      | NJ                           | Betron BS10<br>Earphones<br>Wired<br>Headphones<br>in Ear ...    | B01MA1MJ6H                     | HEADPHONES           | R_01vNlaye  |
| 2       | 2018-12-24    | 8.99                          | 1.0      | NJ                           | NaN                                                              | B078JZTFN3                     | NaN                  | R_01vNlaye  |
| 3       | 2018-12-25    | 10.45                         | 1.0      | NJ                           | Perfecto<br>Stainless<br>Steel<br>Shaving<br>Bowl.<br>Durable... | B06XWF9HML                     | DISHWARE_BOWL        | R_01vNlaye  |
| 4       | 2018-12-25    | 10.00                         | 1.0      | NJ                           | Proraso<br>Shaving<br>Cream for<br>Men                           | B00837ZOI0                     | SHAVING_AGENT        | R_01vNlaye  |
| ...     | ...           | ...                           | ...      | ...                          | ...                                                              | ...                            | ...                  | ...         |
| 1850712 | 2021-04-01    | 6.99                          | 1.0      | MA                           | Tanner's<br>Tasty Paste<br>Vanilla Bling<br>- Anticavit...       | B015ZRTHVA                     | TOOTH_CLEANING_AGENT | R_zfqnsBzlC |
| 1850713 | 2021-04-14    | 15.99                         | 1.0      | MA                           | Sinland<br>Microfiber<br>Cleaning<br>Cloth Dish<br>Cloth K...    | B00QG CXPRG                    | TOWEL                | R_zfqnsBzlC |
| 1850714 | 2021-05-22    | 6.99                          | 4.0      | MA                           | Tanner's<br>Tasty Paste<br>Vanilla Bling<br>- Anticavit...       | B015ZRTHVA                     | TOOTH_CLEANING_AGENT | R_zfqnsBzlC |
| 1850715 | 2021-12-01    | 6.99                          | 4.0      | MA                           | Tanner's<br>Tasty Paste<br>Vanilla Bling<br>- Anticavit...       | B015ZRTHVA                     | TOOTH_CLEANING_AGENT | R_zfqnsBzlC |
| 1850716 | 2022-09-19    | 19.99                         | 1.0      | NaN                          | Wild Mystic<br>Oracle Card<br>Deck: A 50-<br>Card Deck<br>a...   | 1441337652                     | ABIS_BOOK            | R_zfqnsBzlC |

1850717 rows × 8 columns

Оставим только нужные колонки и переназовем их

```
Ввод [48]: 1 data.rename(columns={
2           'Order Date': 'order_dt',
3           'Purchase Price Per Unit': 'unit_price',
4           'Quantity': 'unit_count',
5           'Shipping Address State': 'order_region',
6           'Category': 'product_category',
7           'Survey ResponseID': 'customer_id'
8         }, inplace=True)
9 data.drop(columns=['Title', 'ASIN/ISBN (Product Code)'], inplace=True)
10 data
```

Out[48]:

|         | order_dt   | unit_price | unit_count | order_region | product_category     | customer_id       |
|---------|------------|------------|------------|--------------|----------------------|-------------------|
| 0       | 2018-12-04 | 7.98       | 1.0        | NJ           | FLASH_MEMORY         | R_01vNlayewjIiKMF |
| 1       | 2018-12-22 | 13.99      | 1.0        | NJ           | HEADPHONES           | R_01vNlayewjIiKMF |
| 2       | 2018-12-24 | 8.99       | 1.0        | NJ           | NaN                  | R_01vNlayewjIiKMF |
| 3       | 2018-12-25 | 10.45      | 1.0        | NJ           | DISHWARE_BOWL        | R_01vNlayewjIiKMF |
| 4       | 2018-12-25 | 10.00      | 1.0        | NJ           | SHAVING_AGENT        | R_01vNlayewjIiKMF |
| ...     | ...        | ...        | ...        | ...          | ...                  | ...               |
| 1850712 | 2021-04-01 | 6.99       | 1.0        | MA           | TOOTH_CLEANING_AGENT | R_zfqnsBzIOAKibzb |
| 1850713 | 2021-04-14 | 15.99      | 1.0        | MA           | TOWEL                | R_zfqnsBzIOAKibzb |
| 1850714 | 2021-05-22 | 6.99       | 4.0        | MA           | TOOTH_CLEANING_AGENT | R_zfqnsBzIOAKibzb |
| 1850715 | 2021-12-01 | 6.99       | 4.0        | MA           | TOOTH_CLEANING_AGENT | R_zfqnsBzIOAKibzb |
| 1850716 | 2022-09-19 | 19.99      | 1.0        | NaN          | ABIS_BOOK            | R_zfqnsBzIOAKibzb |

1850717 rows × 6 columns

Посмотрим на типы

```
Ввод [79]: 1 data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1850717 entries, 0 to 1850716
Data columns (total 7 columns):
#   Column              Dtype
---  -
0   order_dt            object
1   unit_price          float64
2   unit_count          float64
3   order_region        object
4   product_category    object
5   customer_id         object
6   unit_revenue        float64
dtypes: float64(3), object(4)
memory usage: 98.8+ MB
```

Заметим, что колонка с датой типа `object`. Исправим это

```
Ввод [80]: 1 data['order_dt'] = pd.to_datetime(data['order_dt'])
```

Заметим, что 1 строка соответствует 1 товару, при этом в заказе мог быть не один товар. К сожалению, у нас есть только дата заказа, так что предположим, что все товары, заказанные пользователем в один день, входят в один заказ. Сгруппируем строки по пользователю и по дате, чтобы собрать заказ

```
Ввод [81]: 1 data['unit_revenue'] = (data['unit_price'] * data['unit_count'])
2 data_order = data.groupby(['customer_id', 'order_dt'])[['unit_revenue', 'unit_c
3 data_order.rename(columns={'unit_revenue': 'order_revenue', 'unit_count': 'item
4 data_order['price_for_one_unit'] = (data_order['order_revenue'] / data_order['i
5 data_order['order_id'] = data_order.index
6 data_order
```


Out[81]:

|        | customer_id       | order_dt   | order_revenue | items_cnt | price_for_one_unit | order_id |
|--------|-------------------|------------|---------------|-----------|--------------------|----------|
| 0      | R_01vNlayewjIiKMF | 2018-12-04 | 7.98          | 1.0       | 7.980              | 0        |
| 1      | R_01vNlayewjIiKMF | 2018-12-22 | 13.99         | 1.0       | 13.990             | 1        |
| 2      | R_01vNlayewjIiKMF | 2018-12-24 | 8.99          | 1.0       | 8.990              | 2        |
| 3      | R_01vNlayewjIiKMF | 2018-12-25 | 20.45         | 2.0       | 10.225             | 3        |
| 4      | R_01vNlayewjIiKMF | 2019-02-18 | 15.98         | 2.0       | 7.990              | 4        |
| ...    | ...               | ...        | ...           | ...       | ...                | ...      |
| 824906 | R_zfqnsBzIOAKibzb | 2021-04-01 | 27.74         | 2.0       | 13.870             | 824906   |
| 824907 | R_zfqnsBzIOAKibzb | 2021-04-14 | 15.99         | 1.0       | 15.990             | 824907   |
| 824908 | R_zfqnsBzIOAKibzb | 2021-05-22 | 27.96         | 4.0       | 6.990              | 824908   |
| 824909 | R_zfqnsBzIOAKibzb | 2021-12-01 | 27.96         | 4.0       | 6.990              | 824909   |
| 824910 | R_zfqnsBzIOAKibzb | 2022-09-19 | 19.99         | 1.0       | 19.990             | 824910   |

824911 rows x 6 columns

Посмотрим на число заказов

```
Ввод [82]: 1 data_cnt_orders = data_order['customer_id'].value_counts()
2 data_cnt_orders.hist(bins=20)
3 plt.xlabel('Кол-во заказов на пользователя')
4 plt.ylabel('Кол-во пользователей')
5 plt.title('Гистограмма кол-ва заказов на пользователя')
6 plt.show()
```



Распределение кол-ва заказов похоже на экспоненциальное.



### 3.3. Пример 1. Оценка ретеншна по году.

С помощью бутстрепа оценим ретеншн покупок пользователей из года в год и сравним ретеншн из 2018 в 2019 год и из 2021 в 2022 год.

```
Ввод [93]: 1 def bootstrap(data, target_col):
2     """
3     Бутстреп данных
4
5     Параметры:
6         data -- датафрейм с выборкой
7         target_col -- колонка с интересующей нас метрикой
8
9     Возвращает:
10        data_boot -- бутстрепная выборка
11    """
12    return data[target_col].sample(frac=1, replace=True)
13
14
15 def count_bootstrap_statistics(data, target_col, boot_fn, stat_fn, n_boot=10_000):
16     """
17     Подсчет бутстрепных статистик методом подстановки
18
19     Параметры:
20         data -- датафрейм с выборкой
21         target_col -- колонка с интересующей нас метрикой
22         boot_fn -- функция, реализующая бутстреп
23         stat_fn -- функция, считающая статистику
24         n_boot -- кол-во запусков бутстрепа
25
26     Возвращает:
27        boot_stat -- массив бутстрепных статистик
28    """
29
30    boot_stat = []
31    for _ in tqdm(range(n_boot)):
32        # бутстрепим данные
33        data_boot = boot_fn(data, target_col)
34        # считаем бутстрепную статистику и добавляем ее в массив
35        boot_stat.append(stat_fn(data_boot))
36
37    return boot_stat
```

```
Ввод [94]: 1 data_order['order_dt'].dtype
```

```
Out[94]: dtype('<M8[ns]')
```

```

Ввод [96]: 1 data_2018_users = data_order[data_order['order_dt'].dt.year == 2018]['customer_
2 data_2019_users = pd.DataFrame(
3     data={'customer_id':data_order[data_order['order_dt'].dt.year == 2019]['cu
4 data_2021_users = data_order[data_order['order_dt'].dt.year == 2021]['customer_
5 data_2022_users = pd.DataFrame(
6     data={'customer_id':data_order[data_order['order_dt'].dt.year == 2022]['cu
7
8 data_2019_users['ret_year'] = data_2019_users['customer_id'].apply(
9     lambda user: 1 if user in data_2018_users else 0)
10 data_2022_users['ret_year'] = data_2022_users['customer_id'].apply(
11     lambda user: 1 if user in data_2021_users else 0)
12
13 data_2022_users

```

Out[96]:

|      | customer_id        | ret_year |
|------|--------------------|----------|
| 0    | R_01vNlayewjIiKMF  | 1        |
| 1    | R_037XK72IZBJyF69  | 1        |
| 2    | R_038ZU6kfQ5f89fH  | 1        |
| 3    | R_03aEbghUILs9Nx D | 1        |
| 4    | R_06RZP9pS7kONINr  | 1        |
| ...  | ...                | ...      |
| 4863 | R_zd4E1BgAdaM2761  | 1        |
| 4864 | R_zdLOP8JD2pe1brj  | 1        |
| 4865 | R_zdQYFhfeqyBd2dH  | 1        |
| 4866 | R_zfnsck2ZatnGtY5  | 1        |
| 4867 | R_zfqnsBzlOAKibzb  | 1        |

4868 rows × 2 columns

```

Ввод [102]: 1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4 # считаем бутстрепные статистики
5 boot_stat = count_bootstrap_statistics(data_2019_users, target_col='ret_year',
6                                     boot_fn=bootstrap, stat_fn=np.mean)
7 # строим бутстрепный дов. интервал
8 lb = np.quantile(boot_stat, q=(1 - alpha)/2)
9 rb = np.quantile(boot_stat, q=(1 + alpha)/2)
10 np.round([lb, rb], 3)

```

100%

10000/10000 [00:01<00:00, 8440.45it/s]

Out[102]: array([0.906, 0.922])

```

Ввод [103]: 1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4 # считаем бутстрепные статистики
5 boot_stat = count_bootstrap_statistics(data_2022_users, target_col='ret_year',
6                                     boot_fn=bootstrap, stat_fn=np.mean)
7 # строим бутстрепный дов. интервал
8 lb = np.quantile(boot_stat, q=(1 - alpha)/2)
9 rb = np.quantile(boot_stat, q=(1 + alpha)/2)
10 np.round([lb, rb], 3)

```

100%

10000/10000 [00:01<00:00, 8086.03it/s]

Out[103]: array([0.974, 0.982])

Сравним полученный интервал с интервалом, который можно получить из ЦПТ

```

Ввод [105]: 1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4
5 # считаем нужные параметры для дов. интервала
6 ret = data_2022_users['ret_year'].mean()
7 stddev = np.sqrt(ret * (1 - ret))
8 z = sps.norm.ppf((1 + alpha) / 2)
9 n = len(data_2022_users)
10
11 # строим дов. интервал по ЦПТ
12 lb = ret - z * stddev / np.sqrt(n)
13 rb = ret + z * stddev / np.sqrt(n)
14 np.round([lb, rb], 3)

```

```
Out[105]: array([0.974, 0.982])
```

Получаем абсолютно такой же интервал.

**Вывод:** ретеншн в покупку из 2018 в 2019 год с 95% вероятностью находится от 90.6% до 92.2%, в то время как ретеншн в покупку из 2021 в 2022 год с 95% вероятностью находится от 97.4% до 98.2%. Это означает, что больше пользователей продолжают совершать покупки на Amazon из года в год.

### 3.4. Задача 1. Оценка доли пользователей, покупающих книги за 2019 год и за 2022 год.

С помощью бутстрепа оцените долю пользователей, покупающих книги за 2019 год и за 2022 год.

```
Ввод [117]: 1 data['product_category'].value_counts()
```

```

Out[117]: product_category
ABIS_BOOK                87619
PET_FOOD                 38256
GIFT_CARD               27734
SHIRT                   27267
NUTRITIONAL_SUPPLEMENT  26913
...
FUEL_INJECTOR            1
FIRE_GRATE               1
NONACTIVATED_GIFT_CARD   1
AUTO_CHEMICAL            1
COMPUTER_VIDEO_GAME_CONTROLLER 1
Name: count, Length: 1871, dtype: int64

```

```
Ввод [118]: 1 data_book = data[data['product_category'] == 'ABIS_BOOK']
2 data_book_2019_users = data_book[data_book['order_dt'].dt.year == 2019]['customer_id']
3 data_book_2022_users = data_book[data_book['order_dt'].dt.year == 2022]['customer_id']
4
5 data_2019_users['buy_book_flg'] = data_2019_users['customer_id'].apply(
6     lambda user: 1 if user in data_book_2019_users else 0)
7 data_2022_users['buy_book_flg'] = data_2022_users['customer_id'].apply(
8     lambda user: 1 if user in data_book_2022_users else 0)
9 data_2022_users
```

Out[118]:

|      | customer_id       | ret_year | buy_book_flg |
|------|-------------------|----------|--------------|
| 0    | R_01vNlayewjIKMF  | 1        | 0            |
| 1    | R_037XK72IZBJyF69 | 1        | 1            |
| 2    | R_038ZU6kfQ5f89fH | 1        | 0            |
| 3    | R_03aEbghUILs9NxD | 1        | 1            |
| 4    | R_06RZP9pS7kONINr | 1        | 1            |
| ...  | ...               | ...      | ...          |
| 4863 | R_zd4E1BgAdaM2761 | 1        | 1            |
| 4864 | R_zdLOP8JD2pe1brj | 1        | 1            |
| 4865 | R_zdQYFhfeqyBd2dH | 1        | 1            |
| 4866 | R_zfnsck2ZatnGtY5 | 1        | 1            |
| 4867 | R_zfqnsBzlOAKibzb | 1        | 1            |

4868 rows × 3 columns

```
Ввод [119]: 1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4 # считаем бутстрепные статистики
5 boot_stat = count_bootstrap_statistics(data_2019_users, target_col='buy_book_flg',
6                                       boot_fn=bootstrap, stat_fn=np.mean)
7 # строим бутстрепный дов. интервал
8 lb = np.quantile(boot_stat, q=(1 - alpha)/2)
9 rb = np.quantile(boot_stat, q=(1 + alpha)/2)
10 np.round([lb, rb], 3)
```

100%

10000/10000 [00:01<00:00, 7274.36it/s]

Out[119]: array([0.531, 0.56 ])

```
Ввод [120]: 1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4 # считаем бутстрепные статистики
5 boot_stat = count_bootstrap_statistics(data_2022_users, target_col='buy_book_flg',
6                                       boot_fn=bootstrap, stat_fn=np.mean)
7 # строим бутстрепный дов. интервал
8 lb = np.quantile(boot_stat, q=(1 - alpha)/2)
9 rb = np.quantile(boot_stat, q=(1 + alpha)/2)
10 np.round([lb, rb], 3)
```

100%

10000/10000 [00:01<00:00, 8529.57it/s]

Out[120]: array([0.547, 0.574])

```
Ввод [121]: 1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4
5 # считаем нужные параметры для дов. интервала
6 ret = data_2022_users['buy_book_flg'].mean()
7 stddev = np.sqrt(ret * (1 - ret))
8 z = sps.norm.ppf((1 + alpha) / 2)
9 n = len(data_2022_users)
10
11 # строим дов. интервал по ЦПТ
12 lb = ret - z * stddev / np.sqrt(n)
13 rb = ret + z * stddev / np.sqrt(n)
14 np.round([lb, rb], 3)
```

```
Out[121]: array([0.547, 0.575])
```

**Вывод:**

- снова бутстрепный дов. интервал и дов. интервал по ЦПТ почти совпали
- доля пользователей, покупающих книги за 2019 и за 2022 год отличаются незначимо

### 3.5. Пример 2. Оценка среднего чека на заказ по годам.

Оценим бутстрепный дов. интервал для среднего чека на заказ за 2019 и за 2022 год.

**Замечание:** в данном случае нужно рассматривать выборку не по пользователям, а по заказам. В предыдущих случаях мы делали неявное предположение, что пользователи независимы друг с другом.

**Сейчас же сделать предположение о независимости мы не можем:** кто-то покупает, например, мало, но много раз, а кто-то — один раз, но очень много.

Средний чек — это отношение суммы всей выручки к кол-ву заказов.

В данном случае мы имеем дело с **метрикой отношения** (подробнее [тут](https://habr.com/ru/companies/X5Tech/articles/740476/) (<https://habr.com/ru/companies/X5Tech/articles/740476/>)).

Что же делать в таком случае? — делать бутстреп по пользователям и брать все их заказы. А дальше — оценивать средний чек как средняя выручка по бутстрепным пользователям!

Ввод [127]:

```

1 def bootstrap_users(data, target_col, user_col='customer_id'):
2     """
3     Делает одну бутстрепную выборку пользователей и возвращает все их заказы.
4
5     Параметры:
6         data -- датафрейм с выборкой
7         target_col -- колонка с интересующей нас метрикой
8         user_col -- колонка с идентификатором пользователя.
9
10    Возвращает:
11        boot_data -- новый датафрейм с бутстреп-выборкой заказов.
12    """
13
14    # Получаем список уникальных пользователей
15    unique_users = data[user_col].unique()
16
17    # Бутстрепим пользователей с возвращением
18    sampled_users = np.random.choice(unique_users, size=len(unique_users), repl
19
20    # Собираем все заказы выбранных пользователей
21    boot_data = data[data[user_col].isin(sampled_users)].copy()
22
23    # Добавим, сколько раз каждый пользователь попал в выборку (важно для повто
24    user_counts = pd.Series(sampled_users).value_counts()
25
26    # Повторим строки в соответствии с количеством выборов пользователя
27    boot_data = boot_data.merge(user_counts.rename("replications"), left_on=user
28    boot_data = boot_data.loc[boot_data.index.repeat(boot_data['replications'])]
29
30    return boot_data

```

Ввод [128]:

```

1 data_2019 = data[data['order_dt'].dt.year == 2019]
2 data_2022 = data[data['order_dt'].dt.year == 2022]
3 data_2022

```

Out [128]:

|         | order_dt   | unit_price | unit_count | order_region | product_category             | customer_id       | ui  |
|---------|------------|------------|------------|--------------|------------------------------|-------------------|-----|
| 130     | 2022-02-13 | 119.99     | 1.0        | NJ           | COMPUTER_DRIVE_OR_STORAGE    | R_01vNlayewjIiKMF |     |
| 131     | 2022-02-17 | 105.99     | 1.0        | NJ           | BED_FRAME                    | R_01vNlayewjIiKMF |     |
| 132     | 2022-02-17 | 12.99      | 1.0        | NJ           | ELECTRONIC_CABLE             | R_01vNlayewjIiKMF |     |
| 133     | 2022-02-17 | 28.89      | 1.0        | NJ           | WIRELESS_ACCESSORY           | R_01vNlayewjIiKMF |     |
| 134     | 2022-02-19 | 11.58      | 1.0        | NJ           | IMMERSION_HEATER             | R_01vNlayewjIiKMF |     |
| ...     | ...        | ...        | ...        | ...          | ...                          | ...               | ... |
| 1850621 | 2022-12-20 | 16.99      | 1.0        | OH           | TRADING_CARDS_FACTORY_SEALED | R_zfnsck2ZatnGtY5 |     |
| 1850622 | 2022-12-20 | 15.66      | 1.0        | OH           | TRADING_CARDS_FACTORY_SEALED | R_zfnsck2ZatnGtY5 |     |
| 1850623 | 2022-12-20 | 7.49       | 1.0        | OH           | TRADING_CARDS_FACTORY_SEALED | R_zfnsck2ZatnGtY5 |     |
| 1850624 | 2022-12-27 | 10.99      | 1.0        | OH           | PLANNER                      | R_zfnsck2ZatnGtY5 |     |
| 1850716 | 2022-09-19 | 19.99      | 1.0        | NaN          | ABIS_BOOK                    | R_zfqnsBzlOAKibzb |     |

442230 rows × 7 columns

Ввод [130]:

```

1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4 # считаем бутстрепные статистики
5 boot_stat = count_bootstrap_statistics(data_2019, target_col='unit_price',
6                                     boot_fn=bootstrap_users, stat_fn=np.mean)
7 # строим бутстрепный дов. интервал
8 lb = np.quantile(boot_stat, q=(1 - alpha)/2)
9 rb = np.quantile(boot_stat, q=(1 + alpha)/2)
10 np.round([lb, rb], 3)

```

100%

10000/10000 [08:50&lt;00:00, 18.66it/s]

Out[130]: array([22.726, 23.527])

Ввод [131]:

```

1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4 # считаем бутстрепные статистики
5 boot_stat = count_bootstrap_statistics(data_2022, target_col='unit_price',
6                                     boot_fn=bootstrap_users, stat_fn=np.mean)
7 # строим бутстрепный дов. интервал
8 lb = np.quantile(boot_stat, q=(1 - alpha)/2)
9 rb = np.quantile(boot_stat, q=(1 + alpha)/2)
10 np.round([lb, rb], 3)

```

100%

10000/10000 [14:37&lt;00:00, 11.74it/s]

Out[131]: array([22.59 , 23.377])

Сравним с дов. интервалом по ЦПТ

Ввод [134]:

```

1 # уровень доверия дов. интервала
2 alpha = 0.95
3
4
5 # считаем нужные параметры для дов. интервала
6 aov = data_2022['unit_price'].mean()
7 stddev = data_2022['unit_price'].std()
8 z = sps.norm.ppf((1 + alpha) / 2)
9 n = len(data_2022_users)
10
11 # строим дов. интервал по ЦПТ
12 lb = aov - z * stddev / np.sqrt(n)
13 rb = aov + z * stddev / np.sqrt(n)
14 np.round([lb, rb], 3)

```

Out[134]: array([21.638, 24.326])

#### Вывод:

- здесь бутстрепный дов. интервал не совпал с интервалом по ЦПТ. Какой же правильный? — по бутстрепу, так как ЦПТ не применима (заказы пользователей не независимы)
- средний чек за 2019 и за 2022 год отличаются незначимо

## 4. Итоги семинара

С чем выходим с занятия:

- разобрались, почему мало не всегда хорошо (парадокс бразильских школ)
- разобрались, почему не всегда удается получить оценки из теории
- узнали, как получать оценки параметров, основываясь только на выборке (бутстреп)
- узнали, как делать бутстреп, если наблюдения зависят от пользователей

## 5. Полезные материалы

- [Парадокс с бразильскими школами \(https://matheusfacure.github.io/python-causality-handbook/03-Stats-Review-The-Most-Dangerous-Equation.html\)](https://matheusfacure.github.io/python-causality-handbook/03-Stats-Review-The-Most-Dangerous-Equation.html)
- [Статья про бутстреп от x5 \(https://habr.com/ru/companies/X5Tech/articles/679842/\)](https://habr.com/ru/companies/X5Tech/articles/679842/)