

Кратко в предыдущих сериях

Советуем перед семинаром освежить в памяти:

- занятие про работу с данными: правила Sanity Check
- занятие про метрики: какие бывают метрики и какие у них свойства
- занятие про визуализации: визуализации в plotly
- Работа с датасетами в pandas
- ...

Тема 6. Методы формирования гипотез из данных. Эксплуаторный анализ.

0. Цель и задачи

Цель — опираясь на знания о продукте, провести первичный анализ данных и сформулировать гипотезы о точках роста продукта.

Задачи:

- узнаем, что значит "изучить данные" и понимать их структуру
- опираясь на занятие про работу с данными, научимся оценивать качество данных
- научимся выявлять аномалии и выбросы
- проведем первичный анализ данных
- научимся сегментному анализу
- поймем, как анализировать воронки
- из первичного анализа, а также знаний о продукте сформулируем гипотезы

1. Вспомним, что было на лекции

1.1 Вопрос в зал: какая структура у гипотезы?

► Сведения

1.2 Попрактикуемся в формировании гипотез

Вспомним, что мы знаем про кейс Yxxxxx.Такси. Какие инсайты у нас уже есть?

- На тарифах **комфорт** и **комфорт+** поездки дороже, чем **эконом**
- На тарифах **эконом** таксисты совершают больше поездок в день
- Тарифы **комфорт** и **комфорт+** иногда переключаются на **эконом**, чтобы у них были заказы
- Таксисты на **комфорт** и **комфорт+** потенциально зарабатывают больше, но разброс больше — кто-то может уехать далеко и дорого, кто-то — просто сидит без заказов. При этом эконом более стабилен, но доход ниже
- Для компании выгоднее, если таксист работает на **более дорогом тарифе** — комиссия и наценка растёт пропорционально среднему чеку
- Большинство клиентов заказывают **эконом**

Вопрос в зал: какие гипотезы можно сгенерировать из этих инсайтов?

► Сведения

2. Разведочательный анализ

Сегодня мы будем работать с датасетом **Social Media Advertisement Performance** на Kaggle. Этот датасет специально создан для моделирования и анализа эффективности рекламных кампаний в социальных сетях.

Данные включают следующие ключевые компоненты:

- Уникальный `user_id` для моделирования пользователей.

- Демографические характеристики (например, возраст, пол, местоположение и другие потенциальные атрибуты).
- Характеристики рекламы и кампаний — возможно, платформа, формат объявления, бюджет, время, цели кампании.
- Логи взаимодействия (например, клики, просмотры, реакции, конверсии).([kaggle.com][1])

Подробнее с датасетом можно ознакомиться [по ссылке \(https://www.kaggle.com/datasets/alperenmyung/social-media-advertisement-performance\)](https://www.kaggle.com/datasets/alperenmyung/social-media-advertisement-performance).

Вопрос в зал: что мы подразумеваем под "пониманием структуры данных"?

► Сведения

Посмотрим на данные

Ввод [87]:

```
1 import pandas as pd
2 import numpy as np
3 import scipy.stats as sps
4 import matplotlib.pyplot as plt
5 from tqdm.notebook import tqdm
6 import random
7 from graphviz import Digraph
8
9 import plotly.express as px
10 import plotly.graph_objects as go
11
12 import seaborn as sns
13
14 sns.set(font_scale=1, palette='Set2')
15 sns.set_style('whitegrid')
```

Ввод [88]:

```
1 events = pd.read_csv('data/ad_events.csv')
2 ads = pd.read_csv('data/ads.csv')
3 campaigns = pd.read_csv('data/campaigns.csv')
4 users = pd.read_csv('data/users.csv')
```

Ввод [89]:

```

1 dfs = [events, ads, campaigns, users]
2 names = ['events', 'ads', 'campaigns', 'users']
3
4 for df, name in zip(dfs, names):
5     print(f'Таблица: {name} \n')
6
7     print("=== Размерность ===")
8     print(f"{df.shape[0]} строк, {df.shape[1]} столбцов")
9
10    print("\n=== Типы данных ===")
11    print(df.dtypes)
12
13    print("\n=== Количество уникальных значений ===")
14    print(df.nunique())
15
16    print("\n=== Первые строки ===")
17    display(df.head())
18
19    print('.' * 50)

```

```

event_id      int64
ad_id          object
user_id        object
timestamp      object
day_of_week    object
time_of_day    object
event_type     object
dtype: object

```

```

=== Количество уникальных значений ===
event_id      400000
ad_id          200
user_id        9950
timestamp      389968
day_of_week      7
time_of_day      4
event_type      6
dtype: int64

```

```

=== Первые строки ===

```


Разберемся, как связаны таблицы

```

Ввод [90]: 1 def draw_er_diagram(tables: dict, relations: list, filename="er_diagram"):
2           dot = Digraph(comment="ER Diagram")
3
4           # добавляем таблицы
5           for table, fields in tables.items():
6               # Делаем label в формате record: {Table|field1 \n field2 \n ...}
7               label = "{" + table + "|" + "\\n".join(fields) + "}"
8               dot.node(table, label, shape="record")
9
10          # добавляем связи
11          for left, right, cardinality in relations:
12              table1, field1 = left.split(".")
13              table2, field2 = right.split(".")
14              dot.edge(table1, table2, label=f"{field1} → {field2} \n ({cardinality})")
15
16          return dot
17
18          tables = dict(zip(names, [df.columns for df in dfs]))
19
20          relations = [
21              ("events.ad_id", "ads.ad_id", "∞:1"),
22              ("events.user_id", "users.user_id", "∞:1"),
23              ("ads.campaign_id", "campaigns.campaign_id", "∞:1"),
24          ]
25
26          dot = draw_er_diagram(tables, relations)
27          dot
28

```

Out [90]:



2.2. Качество данных

Вопрос в зал: что на лекции подразумевалось под качеством данных?

► Сведения

Вопрос в зал: какие могут быть недопустимые значения в этом датасете?

► Сведения

Посмотрим на качество данных в датасете

```
Ввод [91]: 1 for df, name in zip(dfs, names):
2     print(f'Таблица: {name} \n')
3
4     print("\n=== Пропущенные значения ===")
5     print(df.isnull().sum())
6
7     print("\n=== Количество дубликатов по id ===")
8     print(df[df.columns[0]].duplicated().sum())
9
10    print('.' * 50)
11
12    # Преобразуем даты
13    events['timestamp'] = pd.to_datetime(events['timestamp'])
14    campaigns['start_date'] = pd.to_datetime(campaigns['start_date'])
15    campaigns['end_date'] = pd.to_datetime(campaigns['end_date'])
16
17    # Преобразуем интересы из строки в массив
18    if users['interests'].dtype == 'object':
19        users['interests'] = users['interests'].apply(lambda s: s.split(', '))
20    if ads['target_interests'].dtype == 'object':
21        ads['target_interests'] = ads['target_interests'].apply(lambda s: s.split(', '))
22
23    # Некорректные значения
24    print('=== Проверка на некорректные значения: ===')
25
26    print(f"Все возможные дни недели: {events['day_of_week'].unique()}")
27    print(f"Все возможные гендеры: {users['user_gender'].unique()}")
28    print(f"Возраст пользователей в пределах от {users['user_age'].min()} до {users['user_age'].max()}")
29
30    df_full = events.merge(ads, on='ad_id', how='left').merge(campaigns, on='campaign_id', how='left')
31
32    incorrect_timestamp = df_full[df_full.apply(lambda row: row['timestamp'] < row['start_date'], axis=1)]
33    print(f'Некорректные значения: пользователь увидел рекламу до рекламной кампании — {len(incorrect_timestamp)}')
34
35    # удалим некорректные значения
36    incorrect_len_company = df_full[
37        df_full.apply(lambda row: row['duration_days'] != (row['end_date'] - row['start_date'], axis=1)]
38    print(f'Некорректные значения: не совпадает длина рекламной кампании — {len(incorrect_len_company)}')
39
40    incorrect_budget = df_full[df_full['total_budget'] < 0]
41    print(f'Некорректные значения: отрицательный бюджет рекламной кампании — {len(incorrect_budget)}')
42
43    print("\nПропущенные значения:")
44    for column in df_full.columns:
45        print(f"{column}    0")
46    print(f"dtype: int64")
47
48    print("\n=== Количество дубликатов по id ===")
49    print(50)
50    print(".....")
51
52    print("\n=== Проверка на некорректные значения: ===")
53    print(f"Все возможные дни недели: ['Saturday' 'Sunday' 'Friday' 'Thursday' 'Tuesday' 'Monday' 'Wednesday']")
54    print(f"Все возможные гендеры: ['Female' 'Male' 'Other']")
55    print(f"Возраст пользователей в пределах от 16 до 65")
56    print(f"Некорректные значения: пользователь увидел рекламу до рекламной кампании — 66578")
57    print(f"Некорректные значения: не совпадает длина рекламной кампании — 0")
58    print(f"Некорректные значения: отрицательный бюджет рекламной кампании — 0")
```

Что мы видим из значительных проблем датасета:

- несколько дублей в таблице users
- не синхронизированы даты рекламных компаний и даты показов объявлений

Посмотрим на пользователей с дублирующимися строками

Ввод [92]: `1 users.groupby('user_id')['user_gender'].count().sort_values().tail()`

Out[92]:

```
user_id
0ebd6    2
168cf    2
49c5c    2
c4f8e    2
c8620    2
Name: user_gender, dtype: int64
```

Ввод [93]: `1 users[users['user_id'] == '168cf']`

Out[93]:

	user_id	user_gender	user_age	age_group	country	location	interests
4347	168cf	Other	39	35-44	United Kingdom	New Angelaview	[health, food]
7411	168cf	Female	65	55-65	United States	Garciaberg	[gaming, travel]

Видим, что совсем разные соц-дем характеристики, а это значит, что дубли произошли из-за плохого выбора ключа пользователя

Что будем делать с проблемами датасета:

- обработаем дубли: так как в таблице с пользователями нет историчности, оставим любую строчку по пользователю
- вообще в таком случае стоит искать причину такой проблемы: скорее всего, есть глобальная проблема либо в дате показа, либо в датах рекламной кампании. Однако в нашем случае мы удалим такие строчки как некорректные

Ввод [94]: `1 users = users.groupby('user_id').first().reset_index()
2 users`

Out[94]:

	user_id	user_gender	user_age	age_group	country	location	interests
0	00062	Female	16	16-17	France	Davidside	[photography, art, food]
1	00067	Male	38	35-44	United States	East Gary	[travel, gaming, art]
2	00095	Female	28	25-34	United Kingdom	Port Thomas	[photography, fashion]
3	0023e	Female	35	35-44	India	South Lauren	[lifestyle, fitness, health]
4	00336	Female	25	25-34	United States	West Michael	[fashion]
...	...	...	...	...	...	...	...
9945	ffd82	Female	41	35-44	Mexico	Vanessamouth	[technology, fitness, art]
9946	ffe0f	Male	31	25-34	Australia	Tonyaside	[fitness, gaming, news]
9947	ffed3	Male	47	45-54	United Kingdom	Kimberlyburgh	[health, news]
9948	fff7c	Male	33	25-34	United States	South Cynthiashire	[lifestyle]
9949	ffa7	Male	25	25-34	Mexico	South Teresa	[travel, health]

9950 rows × 7 columns

Ввод [95]:

```
1 df_full = df_full[~df_full['event_id'].isin(incorrect_timestamp['event_id'])]
2 df_full.head()
```

Out [95]:

	event_id	ad_id	user_id	timestamp	day_of_week	time_of_day	event_type	campaign_id	ad_platform	ad_type	target_gender
0	1	197	2359b	2025-07-26 00:19:56	Saturday	Night	Like	9	Facebook	Stories	
1	2	51	f9c67	2025-06-15 08:28:07	Sunday	Morning	Share	26	Instagram	Carousel	
2	3	46	5b868	2025-06-27 00:40:02	Friday	Night	Impression	10	Instagram	Carousel	
3	4	166	3d440	2025-06-05 19:20:45	Thursday	Evening	Impression	14	Instagram	Image	
4	5	52	68f1a	2025-07-22 08:30:29	Tuesday	Morning	Impression	2	Instagram	Stories	Female

2.3. Аномалии и выбросы.

Вопрос в зал: что можно сделать, чтобы выявить аномалии и выбросы?

► Сведения

Попробуем выявить аномалии и выбросы

Ввод [96]:

```

1 display(df_full.describe())
2
3 # === Временной ряд: показы всех компаний по дням ===
4
5 df_full['date'] = df_full['timestamp'].dt.date
6 daily_events = df_full.groupby('date')['event_id'].count().reset_index().rename(columns={
7     'event_id': 'events_cnt'})
8 daily_events
9
10 fig = px.line(
11     daily_events, x='date', y='events_cnt',
12     title="Кол-во показов по дням",
13     markers=True
14 )
15 fig.update_traces(mode="lines+markers")
16 fig.update_layout(
17     xaxis_title="День",
18     yaxis_title="Кол-во показов",
19     xaxis_tickangle=-45,
20     template="plotly_white"
21 )
22 fig.show()
23
24 # === Распределение стоимостей компаний ===
25
26 fig = px.histogram(
27     campaigns, x='total_budget',
28     nbins=10,
29     title="Распределение стоимостей компаний",
30     color_discrete_sequence=["#636EFA"]
31 )
32 fig.update_layout(
33     xaxis_title="Бюджет",
34     yaxis_title="Количество компаний",
35     bargap=0.05,
36     template="plotly_white"
37 )
38 fig.add_vline(x=campaigns['total_budget'].mean(), line_dash="dash", line_color="red",
39     annotation_text="Среднее")
40 fig.show()
41
42 # === Boxplot: охват компаний ===
43
44 campaign_coverage = df_full.groupby('ad_id')['user_id'].nunique().reset_index().rename(
45     columns={'user_id': 'users_cnt'})
46
47 fig = px.box(
48     campaign_coverage, y="users_cnt",
49     points="all",
50     template="plotly_white",
51     title='Охват по компаниям'
52 )
53 fig.update_traces(quartilemethod="inclusive")
54 fig.update_layout(
55     yaxis_title="Охват"
56 )
57 fig.show()


```

	event_id	ad_id	timestamp	campaign_id	start_date	end_date	duration_days
count	333422.000000	333422.000000	333422	333422.000000	333422	333422	333422.000000
mean	200075.880203	98.493426	2025-06-26 06:19:54.389245184	24.494284	2025-04-20 20:18:36.941293568	2025-06-25 18:32:16.356929536	65.926151
min	1.000000	1.000000	2025-05-07 14:11:57	1.000000	2025-02-13 00:00:00	2025-04-02 00:00:00	32.000000
25%	100101.250000	49.000000	2025-06-05 07:34:02	13.000000	2025-03-30 00:00:00	2025-05-23 00:00:00	52.000000
50%	200021.500000	98.000000	2025-06-27 18:19:18.500000	24.000000	2025-04-21 00:00:00	2025-06-30 00:00:00	69.000000
75%	300115.750000	149.000000	2025-07-18 14:18:54.249999872	37.000000	2025-05-18 00:00:00	2025-07-23 00:00:00	82.000000
max	400000.000000	200.000000	2025-08-06 14:11:30	50.000000	2025-07-23 00:00:00	2025-10-12 00:00:00	90.000000
std	115497.899709	57.765528	NaN	13.381008	NaN	NaN	17.187925


Кол-во показов по дням



Распределение стоимостей компаний



Охват по компаниям



Ввод [97]: 1 df_full['timestamp'].min(), df_full['timestamp'].max()

Out[97]: (Timestamp('2025-05-07 14:11:57'), Timestamp('2025-08-06 14:11:30'))

- Во временном ряде кол-ва показов выбросы вниз в первый и последний день, но это потому, что в эти дни данные доступны не за весь день. В остальном виден восходящий тренд
- В распределении стоимостей компаний выбросов нет: они распределены между 0 и 100000
- В распределении охватов по компаниям есть более и менее популярные кампании: между ними разница чуть меньше, чем на 1 порядок: 300 против 1900. Выбросов нет

2.4. Связи между переменными

Есть множество способов найти связи между переменными:


- нахождение корреляций
- применение сегментного анализа
- построение графика важности ML-моделей
- изучение коэффициентов линейной регрессии

В этом семинаре мы разберем корреляционный метод и сегментный анализ, а в последующих — остальные методы.

2.4.1. Корреляционный анализ

Дисклеймер:

Мы будем работать с корреляцией Пирсона. Она учитывает линейную связь между показателями, а также не устойчива к выбросам. На практике обычно себя лучше показывает корреляция Спирмена (и иногда корреляция Кендала). Рекомендуется прочитать про эти коэффициенты [на вики](https://ru.wikipedia.org/wiki/%D0%9A%D0%BE%D1%80%D1%80%D0%B5%D0%BB%D1%8F%D1%86%D0%B) (<https://ru.wikipedia.org/wiki/%D0%9A%D0%BE%D1%80%D1%80%D0%B5%D0%BB%D1%8F%D1%86%D0%B>)



Ввод [98]:

```

1 df_click = df_full[df_full['event_type'] == 'Click']
2 campaigns_stat_agg = df_full.groupby('campaign_id')['user_id'].nunique().reset_index().re
3   columns={'user_id': 'users_cnt'})
4 campaigns_clicks = df_click.groupby('campaign_id')['user_id'].nunique().reset_index().ren
5   columns={'user_id': 'clicks_cnt'})
6 campaigns_stat_agg = campaigns_stat_agg.merge(campaigns_clicks, on='campaign_id', how='le
7 campaigns_stat_agg['click_conv'] = campaigns_stat_agg['clicks_cnt'] / campaigns_stat_agg[
8 campaigns_stat_agg = campaigns_stat_agg.merge(campaigns[['campaign_id', 'duration_days',
9   on='campaign_id']).set_index('campaign_id')

```


Ввод [99]:

```

1 # === 6. Корреляционная матрица (2 знака) ===
2
3 corr = campaigns_stat_agg.select_dtypes(include=np.number).corr().round(2)
4
5 fig = px.imshow(
6     corr,
7     text_auto=True,
8     color_continuous_scale="RdBu_r",
9     title="Корреляционная матрица"
10 )
11 fig.update_layout(
12     xaxis_title="Признаки",
13     yaxis_title="Признаки",
14     template="plotly_white"
15 )
16 fig.show()

```

Корреляционная матрица



- Основные метрики (users_cnt, clicks_cnt, click_conv) сильно связаны между собой
- Продолжительность кампании (duration_days) не играет роли
- Бюджет (total_budget) влияет, но не сильно

2.4.2. Сегментный анализ

Напомним, что **сегментация** — это метод, в котором мы ищем разрезы, в которых отличаются ключевые показатели. Мы хотим понять, какие показатели влияют на охват рекламной кампании и конверсию в клик.

Для начала нам нужно определить метрики, которые могут влиять на показатели

Вопрос в зал: что может влиять на охват и конверсию в клик?

► Сведения


- Пойдем с самого очевидного: разделим бюджет кампании на группы до 35 тыс., 35-65 тыс. и более 65 тыс. и посмотрим в

```


Ввод [236]: 1 campaigns_stat_agg['budget_rank'] = campaigns_stat_agg['total_budget'].apply(
2             lambda x: 0 if x < 35000 else 1 if x < 65000 else 2)
3
4 # === 5. Boxplot: продажи по сегментам ===
5
6 fig = px.box(
7     campaigns_stat_agg, x="budget_rank", y="users_cnt", color="budget_rank",
8     title="Boxplot охватов по уровню бюджета",
9     points="all",
10    template="plotly_white"
11 )
12 fig.update_traces(quartilemethod="inclusive")
13 fig.update_layout(
14     xaxis_title="Уровень бюджета",
15     yaxis_title="Охват"
16 )
17 fig.show()
18
19 fig = px.box(
20     campaigns_stat_agg, x="budget_rank", y="click_conv", color="budget_rank",
21     title="Boxplot конверсий в клик по уровню бюджета",
22     points="all",
23     template="plotly_white"
24 )
25 fig.update_traces(quartilemethod="inclusive")
26 fig.update_layout(
27     xaxis_title="Уровень бюджета",
28     yaxis_title="Конверсия в клик"
29 )
30 fig.show()

```

Boxplot охватов по уровню бюджета



Boxplot конверсий в клик по уровню бюджета



Стоит заметить, что точек довольно мало, но в обоих случаях одинаковые паттерны поведения: "дешевые" кампании приносят довольно маленькие охваты и конверсии, а кампании дороже 35 тыс. приносят больше пользователей и кликов. При этом разницы между "дорогой" и "средней по цене" кампаниями не наблюдается

- Перейдем к сравнению интересов. Посмотрим на конверсию в клик среди интересов, совпадающих и не совпадающих с рекламной компанией

Для начала сделаем one-hot интересов пользователей и реклам.

Ввод [172]:

```
1 one_hot = users["interests"].explode().str.get_dummies().groupby(level=0).sum()
2 # Объединяем с исходным датафреймом
3 users_one_hot = users.drop(columns=["interests"]).join(one_hot)
4
5 one_hot_ads = pd.get_dummies(ads["target_interests"].explode(), prefix='target').groupby(level=0).sum()
6 ads_with_one_hot = ads[["ad_id"]].join(one_hot_ads)
7 df_full_one_hot = df_full.drop(columns=["target_interests"]).merge(ads_with_one_hot, on='ad_id')
8 df_full_users = df_full_one_hot.merge(users_one_hot, on='user_id', how='left')
9 df_full_users.head()
```

Out [172]:

	event_id	ad_id	user_id	timestamp	day_of_week	time_of_day	event_type	campaign_id	ad_platform	ad_type	...	fitness
0	1	197	2359b	2025-07-26 00:19:56	Saturday	Night	Like	9	Facebook	Stories	...	0
1	2	51	f9c67	2025-06-15 08:28:07	Sunday	Morning	Share	26	Instagram	Carousel	...	0
2	3	46	5b868	2025-06-27 00:40:02	Friday	Night	Impression	10	Instagram	Carousel	...	0
3	4	166	3d440	2025-06-05 19:20:45	Thursday	Evening	Impression	14	Instagram	Image	...	0
4	5	52	68f1a	2025-07-22 08:30:29	Tuesday	Morning	Impression	2	Instagram	Stories	...	0

5 rows × 49 columns

Ввод [173]:

```

1 interests = users['interests'].explode().unique()
2
3 df_full_users['interest_coincidence'] = 0
4 for interest in interests:
5     df_full_users['interest_coincidence'] += (df_full_users[interest] * df_full_users[f't
6
7 df_full_users.loc[df_full_users['interest_coincidence'] > 0, 'interest_coincidence'] = 1
8 df_full_users.head()

```

Out[173]:

	event_id	ad_id	user_id	timestamp	day_of_week	time_of_day	event_type	campaign_id	ad_platform	ad_type	...	food	g
0	1	197	2359b	2025-07-26 00:19:56	Saturday	Night	Like	9	Facebook	Stories	...	1	
1	2	51	f9c67	2025-06-15 08:28:07	Sunday	Morning	Share	26	Instagram	Carousel	...	0	
2	3	46	5b868	2025-06-27 00:40:02	Friday	Night	Impression	10	Instagram	Carousel	...	0	
3	4	166	3d440	2025-06-05 19:20:45	Thursday	Evening	Impression	14	Instagram	Image	...	1	
4	5	52	68f1a	2025-07-22 08:30:29	Tuesday	Morning	Impression	2	Instagram	Stories	...	0	

5 rows × 50 columns

Ввод [183]:


```

1 def segment_analysis(df, group_cols, segment_col, user_col='user_id',
2                       event_col='event_type', event_type='Click'):
3     df_group = df.groupby(group_cols)[user_col].nunique().reset_index().rename(columns={
4         user_col: 'users_cnt'})
5
6     df_conv = df[df[event_col] == event_type]
7     df_group_conv = df_conv.groupby(group_cols)[user_col].nunique().reset_index().rename(
8         user_col: f'{event_type}_cnt')
9     df_group = df_group.merge(df_group_conv, on=group_cols)
10    df_group[f'{event_type}_conv'] = df_group[f'{event_type}_cnt'] / df_group['users_cnt']
11
12    fig = px.box(
13        df_group, x=segment_col, y=f'{event_type}_conv', color=segment_col,
14        title=f"Boxplot конверсий в {event_type} по {segment_col}",
15        points="all",
16        template="plotly_white"
17    )
18    fig.update_traces(quartilemethod="inclusive")
19    fig.update_layout(
20        xaxis_title=segment_col,
21        yaxis_title=f'Конверсия в {event_type}'
22    )
23    fig.show()

```

```
Ввод [184]: 1 segment_analysis(df_full_users, ['ad_id', 'interest_coincedence'], 'interest_coincedence')
```

Boxplot конверсий в Click по interest_coincedence




Вопрос в зал: есть связь? Почему у элементов с совпадением интересов больше дисперсия?

► Сведения

- Возраст и совпадение возраста с рекламной компанией

```
Ввод [185]: 1 segment_analysis(df_full_users, ['ad_id', 'age_group'], 'age_group')
```

Boxplot конверсий в Click по age_group



Ввод [186]:

```

1 df_full_users['age_coinedence'] = (df_full_users['target_age_group'] == 'All').astype(int)
2 df_full_users['age_coinedence'] += (df_full_users['age_group'] == df_full_users['target_age_group']).astype(int)
3
4 df_full_users.head()

```

Out[186]:

	event_id	ad_id	user_id	timestamp	day_of_week	time_of_day	event_type	campaign_id	ad_platform	ad_type	...	gaming
0	1	197	2359b	2025-07-26 00:19:56	Saturday	Night	Like	9	Facebook	Stories	...	1
1	2	51	f9c67	2025-06-15 08:28:07	Sunday	Morning	Share	26	Instagram	Carousel	...	0
2	3	46	5b868	2025-06-27 00:40:02	Friday	Night	Impression	10	Instagram	Carousel	...	0
3	4	166	3d440	2025-06-05 19:20:45	Thursday	Evening	Impression	14	Instagram	Image	...	0
4	5	52	68f1a	2025-07-22 08:30:29	Tuesday	Morning	Impression	2	Instagram	Stories	...	0

5 rows × 51 columns


Ввод [187]:

```

1 segment_analysis(df_full_users, ['ad_id', 'age_coinedence'], 'age_coinedence')

```

Boxplot конверсий в Click по age_coinedence




По возрасту есть ощущение, что реклама лучше влияет на более людей 45+, однако старшего поколения поменьше, так это не такая сильная гипотеза

По совпадению возраста человека и рекламной кампании не видна связь с конверсией в клик

- По полу

```
Ввод [188]: 1 segment_analysis(df_full_users, ['ad_id', 'user_gender'], 'user_gender')
```

Boxplot конверсий в Click по user_gender



По полу человека взаимосвязи с конверсией в клик не наблюдается


Практика: используя функцию, визуализируйте боксплот по времени дня взаимодействия с рекламой и сделайте вывод

```
Ввод [190]: 1 ...
```

Out[190]: Ellipsis

```
Ввод [191]: 1 segment_analysis(df_full_users, ['ad_id', 'time_of_day'], 'time_of_day')
```

Boxplot конверсий в Click по time_of_day



По времени взаимодействия с рекламой связи тоже нет

2.5. Анализ воронки

Вопрос в зал: перед вами ивенты, которые могут быть. Какие можно выделить стадии воронки?

```
Ввод [192]: 1 df_full_users['event_type'].value_counts()
```

```
Out[192]: event_type
Impression    283275
Click          33419
Like           9949
Comment        3443
Purchase       1686
Share          1650
Name: count, dtype: int64
```

► Сведения

Ввод [196]:

```
1 df_full_users['event_level'] = df_full_users['event_type'].apply(lambda t: 0 if t == 'Imp
2                                     else 1 if t == 'Click' \
3                                     else 2 if t in ['Like',
4                                     else 3)
5 df_full_users.head()
```

Out[196]:

	event_id	ad_id	user_id	timestamp	day_of_week	time_of_day	event_type	campaign_id	ad_platform	ad_type	...	health
0	1	197	2359b	2025-07-26 00:19:56	Saturday	Night	Like	9	Facebook	Stories	...	0
1	2	51	f9c67	2025-06-15 08:28:07	Sunday	Morning	Share	26	Instagram	Carousel	...	0
2	3	46	5b868	2025-06-27 00:40:02	Friday	Night	Impression	10	Instagram	Carousel	...	0
3	4	166	3d440	2025-06-05 19:20:45	Thursday	Evening	Impression	14	Instagram	Image	...	0
4	5	52	68f1a	2025-07-22 08:30:29	Tuesday	Morning	Impression	2	Instagram	Stories	...	0

5 rows × 52 columns

```
1 Посмотрим на связь конверсий в воронке в зависимости от платформы и от типа рекламы
```

Ввод [198]:

```
1 df_ad_group = df_full_users.groupby(['user_id', 'ad_id'])['event_level'].max().reset_index()
2 df_ad_group = df_ad_group.merge(ads, on='ad_id')
3 df_ad_group
```

Out[198]:

	user_id	ad_id	event_level	campaign_id	ad_platform	ad_type	target_gender	target_age_group	target_interests
0	00062	2	1	33	Facebook	Stories	All	25-34	[travel, photography]
1	00336	2	0	33	Facebook	Stories	All	25-34	[travel, photography]
2	00567	2	0	33	Facebook	Stories	All	25-34	[travel, photography]
3	006ce	2	0	33	Facebook	Stories	All	25-34	[travel, photography]
4	007b8	2	0	33	Facebook	Stories	All	25-34	[travel, photography]
...	...	...	...	...	...	...	...	...	...
304619	ff30f	119	0	44	Instagram	Carousel	All	35-44	[health]
304620	ff3b2	119	0	44	Instagram	Carousel	All	35-44	[health]
304621	ff50e	119	1	44	Instagram	Carousel	All	35-44	[health]
304622	ff8e1	119	0	44	Instagram	Carousel	All	35-44	[health]
304623	ffa49	119	0	44	Instagram	Carousel	All	35-44	[health]

304624 rows × 9 columns

Ввод [218]:

```

1 df_ad_group_platform = df_ad_group.groupby(['ad_platform', 'event_level'])[
2     'user_id'].count().reset_index().rename(columns={'user_id': 'user_cnt'})
3 df_ad_group_platform["user_cnt"] = (
4     df_ad_group_platform.sort_values("event_level", ascending=False).groupby(
5         "ad_platform")["user_cnt"].cumsum())
6 # Максимум (уровень 0) на каждую платформу
7 df_ad_group_platform["total"] = df_ad_group_platform.groupby("ad_platform")["user_cnt"].t
8
9 # Процент от верхнего уровня
10 df_ad_group_platform["conversion_rate"] = np.round(
11     df_ad_group_platform["user_cnt"] / df_ad_group_platform["total"], 4)
12 df_ad_group_platform

```

Out[218]:

	ad_platform	event_level	user_cnt	total	conversion_rate
0	Facebook	0	202518	202518	1.0000
1	Facebook	1	32902	202518	0.1625
2	Facebook	2	11048	202518	0.0546
3	Facebook	3	1143	202518	0.0056
4	Instagram	0	102106	102106	1.0000
5	Instagram	1	16633	102106	0.1629
6	Instagram	2	5615	102106	0.0550
7	Instagram	3	543	102106	0.0053


Ввод [232]:

```

1 data = dict(Quantity=df_ad_group_platform['conversion_rate'],
2             Stage=['Показы', 'Клики', 'Взаимодействия', 'Покупки']*2,
3             Process=df_ad_group_platform['ad_platform'])
4
5 fig = px.funnel(data, y='Stage', x='Quantity', color='Process',
6                 color_discrete_map={"Старый": "#374B53",
7                                     "Новый": "#A4B7C8"},
8                 template="simple_white",
9                 title='Сравнение разных каналов рекламы',
10                 labels={"Stage": ""})
11
12 fig.update_traces(textinfo="percent initial", textfont=dict(size=16))
13
14 fig.show()

```

Сравнение разных каналов рекламы



Ввод [234]:

```

1 df_ad_group_type = df_ad_group.groupby(['ad_type', 'event_level'])[
2     'user_id'].count().reset_index().rename(columns={'user_id': 'user_cnt'})
3 df_ad_group_type["user_cnt"] = (
4     df_ad_group_type.sort_values("event_level", ascending=False).groupby(
5         "ad_type")["user_cnt"].cumsum())
6 # Максимум (уровень 0) на каждую платформу
7 df_ad_group_type["total"] = df_ad_group_type.groupby("ad_type")["user_cnt"].transform("max")
8
9 # Процент от верхнего уровня
10 df_ad_group_type["conversion_rate"] = np.round(
11     df_ad_group_type["user_cnt"] / df_ad_group_type["total"], 4)
12 df_ad_group_type

```

Out[234]:


	ad_type	event_level	user_cnt	total	conversion_rate
0	Carousel	0	75246	75246	1.0000
1	Carousel	1	12094	75246	0.1607
2	Carousel	2	4094	75246	0.0544
3	Carousel	3	420	75246	0.0056
4	Image	0	81595	81595	1.0000
5	Image	1	13312	81595	0.1631
6	Image	2	4436	81595	0.0544
7	Image	3	436	81595	0.0053
8	Stories	0	97647	97647	1.0000
9	Stories	1	15936	97647	0.1632
10	Stories	2	5401	97647	0.0553
11	Stories	3	559	97647	0.0057
12	Video	0	50136	50136	1.0000
13	Video	1	8193	50136	0.1634
14	Video	2	2732	50136	0.0545
15	Video	3	271	50136	0.0054

```

Ввод [235]: 1 def plot_funnel(funnel_df=df_ad_group_type, segment_col='ad_type', title='Сравнение по ти
2             fig = px.bar(
3                 funnel_df,
4                 x="event_level",
5                 y="conversion_rate",
6                 color=segment_col,
7                 barmode="group",
8                 color_discrete_sequence=px.colors.qualitative.Vivid
9             )
10            fig.update_layout(
11                title=title,
12                yaxis_title="Конверсия (%)",
13                xaxis_title="Этап",
14                template="plotly_white",
15                bargap=0.2
16            )
17            fig.show()
18
19 # Визуализация
20 plot_funnel()

```

Сравнение по типу рекламы



Кажется, нет влияния на конверсии ни платформы, ни типа взаимодействия.

2.6. Вывод по кейсу

- Данные по показам: тренд растущий, выбросы только из-за неполных дней.
- Основные метрики (users_cnt, clicks_cnt, click_conv) движутся синхронно.
- Продолжительность кампании значения не имеет.
- Бюджет оказывает умеренное влияние: "дешёвые" кампании → низкий охват, дорогие (>35k) → выше, но прирост с ростом бюджета после порога небольшой.
- Возраст: лучше откликаются 45+, но таких пользователей меньше.
- Ни пол, ни интересы, ни платформа, ни время суток не влияют на конверсии.

Практика: сформулируйте гипотезы, которые можно сделать из этих выводов

▼ Сведения

1. **Оптимизация бюджета:** если мы **будем удерживать бюджет кампаний в среднем диапазоне (35-50k)**, то получим **увеличение охвата и кликов**. Действие замерим через **охват** и **конверсию в клик**, которые вырастут на **7–10%** по сравнению с низкобюджетными кампаниями.
2. **Фокус на аудитории 45+:** если мы **нацелим часть кампаний на пользователей 45+**, то повысим **конверсию из показа в клик** в этом сегменте. Действие заметим через **CTR**, который увеличится на **5–7%** для этой аудитории.
3. **Сокращение неэффективных параметров** если мы **перестанем тратить время на настройку по полу, интересам, платформам и времени суток**, то сохраним ресурсы и не потеряем эффективность. Действие заметим через **стабильность CTR и CR** (без падения, **изменения $\leq 1\%$**).

3. Итоги семинара

- разобрались на практике, что значит понимать структуру данных и оценивать их качество
- проверили данные на "адекватность", нашли некорректные значения
- попробовали выявить аномалии и выбросы через боксплоты, построение распределений и динамики метрики во времени
- провели первичный анализ данных: посмотрели корреляции между параметрами, поработали с сегментным анализом и с воронкой
- сформировали гипотезы из EDA

4. Полезные материалы

- [Игра: угадай корреляцию \(https://www.guessthecorrelation.com/\)](https://www.guessthecorrelation.com/)
- [Статья про странные корреляции \(https://habr.com/ru/articles/236503/\)](https://habr.com/ru/articles/236503/)